



浙江农业学报
Acta Agriculturae Zhejiangensis
ISSN 1004-1524, CN 33-1151/S

《浙江农业学报》网络首发论文

题目：基于 YOLOv8n 改进的杂草轻量检测算法
作者：朱洪廷，方睿，肖潇，蔡鑫地，何兵
收稿日期：2025-07-19
网络首发日期：2026-08-19
引用格式：朱洪廷，方睿，肖潇，蔡鑫地，何兵. 基于 YOLOv8n 改进的杂草轻量检测算法[J/OL]. 浙江农业学报. <https://link.cnki.net/urlid/33.1151.s.20260819.1459.004>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

朱洪廷, 方睿, 肖潇, 等. 基于 YOLOv8n 改进的杂草轻量检测算法[J]. 浙江农业学报, 2026, 38 (9)

DOI:10.3969/j.issn.1004-1524.20250494

基于 YOLOv8n 改进的杂草轻量检测算法

朱洪廷, 方睿*, 肖潇, 蔡鑫地, 何兵

(成都信息工程大学 计算机学院, 四川 成都 610225)

摘要: 针对农业场景中杂草检测模型中参数量大、多尺度特征融合效率低、遮挡环境下检测精度不足等问题, 提出一种基于改进 YOLOv8 的轻量级模型 CDMC-YOLO。设计一种融合邻近上下文与全局上下文的特征增强模块 (contextual feature enhancement, CFE), 将其集成至 C2f 模块, 以提升对边缘模糊目标的检测精度; 设计一种轻量级共享卷积检测头 (DWConv-lightweight shared convolutional detection, DLSCD), 以降低计算成本; 引入多尺度空洞注意力 (multi-scale dilated attention, MSDA) 机制, 增强模型对遮挡目标和复杂背景的感知能力; 利用跨尺度特征融合模块 (cross-scale feature fusion module, CCFM) 优化特征金字塔结构, 采用通道拼接与简化的卷积操作替代冗余的多层级联。实验结果表明, CDMC-YOLO 的参数量与计算量较 YOLOv8n 分别减少 40.0% 与 23.2%, 精度均值 (mAP@0.5) 提升 2.1 个百分点, 为农业智能化除草提供了高效解决方案。

关键词: 深度学习; 杂草检测; 跨尺度融合; 特征增强; 轻量化模型

中图分类号: TP391.41

文献标志码: A

文章编号: 1004-1524 (2026) 09-0000-00

Improved lightweight weed-detection algorithm based on YOLOv8n

ZHU Hongting, FANG Rui*, XIAO Xiao, CAI Xindi, HE Bing

(School of Computer Science, Chengdu University of Information Technology, Chengdu 610225, China)

Abstract: To address the issues of excessive parameters, inefficient multi-scale feature fusion, and insufficient detection accuracy under occlusion in weed detection models for agricultural scenes, this paper proposes CDMC-YOLO, a lightweight model based on an improved YOLOv8 architecture. A contextual feature enhancement (CFE) module, which integrates adjacent and global context, is designed and integrated into the C2f module to improve detection accuracy for edge-blurred targets. A lightweight shared convolutional detection head (DWConv-lightweight shared convolutional detection, DLSCD) is designed to reduce computational costs. By incorporating a multi-scale dilated attention (MSDA) mechanism, the model's perception capability for occluded targets and complex backgrounds is enhanced. Furthermore, a cross-scale feature fusion module (CCFM) is introduced to optimize the feature pyramid structure, replacing redundant multi-layer cascades with channel concatenation and simplified convolution operations. Experimental results demonstrate that CDMC-YOLO reduces parameters and computational load by 40.0% and 23.2% respectively, compared to YOLOv8n, while increasing mean average precision (mAP@0.5) by 2.1 percentage points. This study provides an efficient solution for intelligent agricultural weeding.

Key words: deep learning; weed detection; cross scale fusion; feature enhancement; lightweight model

在农田生态系统中, 杂草不仅与作物竞争光、水和养分资源, 抑制作物生长, 还会携带病虫害, 降低产量与品质, 并增加机械化收获难度^[1]。

当前, 杂草检测技术主要包括光谱识别法^[2]、遥感检测^[3]和机器视觉方法^[4]。其中, 光谱识别与遥感检

收稿日期: 2025-07-19

作者简介: 朱洪廷, 研究方向为机器视觉。E-mail: 377895550@qq.com

*通信作者, 方睿, E-mail: fangrui@cuit.edu.cn

测技术依赖专业采集设备,成本高昂且受环境条件限制,难以在中小型农场普及。传统的机器视觉方法(如形态学与纹理分类)因特征稳健性不足、计算复杂度过高,难以应对田间复杂光照与遮挡场景^[5]。近年来,以 YOLO 系列为代表的深度学习模型凭借其端到端的检测框架与多尺度特征适应能力,在农业目标识别领域取得显著进展^[6-7]。机器视觉系统在实现集成、可持续的杂草管理方面越来越受到关注。

针对模型优化:文韬等^[8]提出改进的 YOLOv8 轻量级检测算法,通过融合 MSBlock 模块与异构卷积增强主干网络性能,并引入高效局部注意力机制优化特征金字塔结构,然而,该模型存在推理效率较低的问题,且在目标遮挡场景下的检测性能有待提升。Li 等^[9]结合对偶坐标注意力(dual coordinate attention, DCA)模型和内容感知特征重组算子(content-aware reassembly of features, CARAFE),提升关键特征提取能力,但此模型计算复杂度较高,难以满足实时检测应用的需求。Kavitha 等^[10]基于 YOLOv5 构建大豆田杂草检测模型,采用特征图融合与交叉优化算法强化全局信息利用,但该模型对不同生长期杂草检测的稳健性不足。冯泰株等^[11]在 YOLOv7 中集成自适应特征收集再分配模块(adaptive feature collection and redistribution, AFRCR),有效提升了小目标检测精度和模型泛化性,但该模型在轻量化设计方面存在欠缺,且在遮挡环境下的检测效果不佳。Zheng 等^[12]通过引入批量归一化(batch normalization, BN),设计了轻量级共享卷积 BN 检测头,显著降低了模型的计算复杂度,同时采用 LSK 模块扩大特征感受野,提升检测精度;然而,该方法在处理多时期杂草所呈现的多尺度特征检测任务时可能存在局限性。

根据区域候选机制差异,主流检测模型可分为双阶段与单阶段两大类。作为单阶段检测器的典型代表,YOLO 系列采用端到端的检测范式,摒弃了传统的区域建议步骤,通过预设网格划分或锚点机制直接回归目标参数。这种设计理念显著提升了检测效率,使其在实时检测场景中展现明显优势。在模型的实际应用中,我们首先需要考虑的是,模型能否适配多种硬件设备,是否易于迁移、维护与更新,以及推理速度是否满足实时性要求等关键问题。YOLOv8 作为 YOLO 系列中应用最广泛的版本,不仅推理速度快、响应迅速,还在检测精度与推理速度上实现了平衡性突破,其特征提取网络融合了 YOLOv7 的高效层聚合网络(efficient layer aggregation network, ELAN)模块设计理念,将原有的 C3 模块升级为优化梯度传播的 C2f 架构,同时引入动态通道调节机制以适应多样化应用场景,因此适合作为改进的基础模型^[13]。此外,YOLOv8 具有较高的稳定性和兼容性,更适合部署于边缘设备。相比之下,最新发布的模型由于推出时间较短,代码尚不稳定,部署支持也较为有限,不宜直接投入实际应用。因此,本文选择 YOLOv8n 作为基线模型。但是,该模型在农业场景中仍存在计算成本高、缺乏针对多尺度遮挡的注意力机制,导致小目标与重叠目标漏检率较高等局限性^[13]。为应对上述挑战,提升模型对复杂环境下杂草的检测精度并降低其参数量与计算开销,本研究对 YOLOv8 模型进行改进,提出 CDMC-YOLO 模型。主要贡献如下:1)针对幼苗期杂草特征微弱、边缘模糊导致检测精度低的问题,设计上下文特征增强模块(contextual feature enhancement, CFE),用 C2f_CFE 模块替换原模型中的 C2f 模块,通过融合邻近局部信息与全局上下文信息,显著提升了模型对幼苗边缘等低响应特征的感知与表征能力。2)为优化模型在资源受限场景下的适用性,减少模型参数量,设计一种轻量级共享卷积检测头 DLSCD(DWConv-LIGHTWEIGHT SHARED CONVOLUTIONAL DETECTION)。3)为有效建模叶片相互重叠形成的复杂遮挡模式,引入了多尺度空洞注意力机制(multi-scale dilated attention, MSDA),通过设定四级稀疏率(1,2,3,4)适配不同尺度的叶片遮挡结构,强化模型在遮挡场景下的特征聚焦能力。4)针对作物与杂草在颜色、纹理特征上相似度高、通用特征金字塔结构难以有效区分的难题,使用跨尺度特征融合模块(cross-scale feature fusion module, CCFM)以增强作物-杂草特征区分度,在降低参数量的同时提升检测精度。


1 材料与方法

1.1 CDMC-YOLO 模型

1.1.1 整体结构

针对 YOLOv8 在农业杂草检测场景中存在的计算复杂度高、多尺度特征融合效率低、遮挡目标感知能力弱,以及幼苗边缘特征提取不足等问题,本研究提出一种轻量级改进模型 CDMC-YOLO(图 1)。该模型

在继承 YOLOv8 高效单阶段检测框架的基础上，通过 4 项核心创新实现性能优化：1) 设计 CFE 模块并集成至 C2f 架构，提升模型对模糊边缘特征的判别能力；2) 设计一种轻量级共享卷积检测头替代原有检测头，显著降低模型复杂度与计算开销；3) 嵌入多尺度空洞注意力（MSDA）机制，增强模型对遮挡目标的稳健性；4) 采用 CCFM 重构颈部网络（neck），提升模型的多尺度特征融合效率。



Backbone，骨干网络；Neck，颈部网络；Head，头部网络；Conv，卷积模块；C2f_CFE，上下文特征增强卷积模块；Contact，特征拼接层；MaxPool2d，最大池化层；Upsample，动态上采样模块；DLSCD，轻量级共享卷积检测头；MSDA，多尺度空洞注意力机制；SPPF，空间金字塔快速池化模块。下同。

DLSCD, DWConv-lightweight shared convolutional detection; MSDA, Multi-scale dilated attention; SPPF, Spatial pyramid pooling- fast. The same as below.

图 1 CDMC-YOLO 模型结构

Fig. 1 Structure of CDMC-YOLO model

1.1.2 C2f_CFE 模块

为了解决杂草检测中存在的复杂场景下对象边缘不清、背景杂乱和尺度变化多样等问题，本文设计了一种新的特征增强模块 CFE，并将其加入 C2f 中，设计了一种新的 C2f 模块——C2f_CFE。

自适应特征增强（adaptive feature enhancement, AFE）模块，由 Ali 等^[14]为解决语义分割在杂乱背景下的检测不精等问题提出，通过利用空间上下文模块和特征精炼模块来增强特征信息，使模块在多个阶段提出更全面的特征，以更好地区分对象边界。在杂草检测中，需要捕获局部特征（如叶片锯齿、脉络等边缘特征）并聚焦不同尺度的关键特征（如幼苗的微小叶片与成熟植株的大面积轮廓）。为此，本文对其中的空间上下文模块进行修改，设计 CFE 模块，通过结合邻近上下文与全局上下文信息来增强特征信息，提高模块对上下文的感知，增强模型对复杂特征的检测能力。CFE 模块由 3 个核心子模块构成——卷积嵌入（convolutional embedding, CE）模块、全局上下文 transformer（Contextual Transformer, CoT）模块、特征精炼模块（Feature Refinement Module, FRM），其处理流程形式化描述如下。

首先，对输入特征张量 X 经过一个深度卷积后实施层归一化（LayerNorm）处理，对特征进行初步增强：

$$X_0 = \text{LayarNorm}[\text{DWConv}(X)]. \quad (1)$$

随后，将其输入 CE 模块进行特征转换。该模块采用 1×1 卷积核实现通道维度降维操作（通道压缩率为 50%）：

$$X_1 = \text{LayerNorm}[\text{Conv}_{0.5}(X_0)]。 \quad (2)$$

此设计具有双重优势：其一，通过降低特征维度有效控制计算复杂度；其二，促进跨通道特征交互，从而增强特征的泛化表征能力与类别判别性。

经 CE 处理的特征 X_1 并行输入 CoT 与 FRM 两个分支。在 FRM 中，首先使用深度卷积对输入特征 X_1 进行下采样，下采样后的特征图分辨率下降，有利于捕捉低频信息，再使用双线性插值上采样将下采样后的特征图恢复到原尺寸，重构为低频特征：

$$X_2 = \text{Upsample}[\text{DWConv}(X_1)] \quad (3)$$

随后，利用逐元素乘法操作对原始特征与低频特征进行调制，生成细化后的低频特征：

$$X_3 = X_1 \bullet X_2。 \quad (4)$$

之后通过残差计算分离高频细节信息：

$$X_4 = X_1 - X_3。 \quad (5)$$

最后，通过通道维度拼接将低频特征与高频特征融合得到最终输出，实现全局结构与局部细节的互补优化。

$$X_5 = X_3 + X_4。 \quad (6)$$

在 CoT 模块中，首先对输入 X_1 定义 $K = X_1, Q = X_1, V = X_1 W_v$ ，其中， W_v 为卷积权重矩阵（ 1×1 卷积），即只对 V 进行特征映射，然后通过 $k \times k$ 分组卷积获取邻近上下文信息，形成 K_1 ：

$$K_1 = \text{Conv}_{k \times k}(K)。 \quad (7)$$

再与 Query 拼接，然后通过两个 1×1 卷积生成注意力矩阵：

$$A = [K_1, Q] W_\theta W_\delta。 \quad (8)$$

式（8）中： W_θ 为使用 ReLU 激活函数的卷积， W_δ 为不使用激活函数的卷积。

Value Map 通过 1×1 卷积后与上述得到的注意力矩阵相乘得到 K_2 ：

$$K_2 = V \otimes A。 \quad (9)$$

式（9）中的 $\otimes$ 表示矩阵乘法。


之后， K_1 与 K_2 通过注意力机制融合得到最终输出：

$$X_6 = K_1 \times K_2。 \quad (10)$$

最终，将 CoT 分支输出的全局上下文特征与 FRM 生成的多尺度特征进行通道维度拼接，并经由 1×1 卷积核实施特征融合与维度规整：

$$Y = \text{Conv}_{1 \times 1}[\text{Concat}(X_5, X_6)]。 \quad (11)$$

CoT 模块通过自注意力机制捕获长程依赖关系，并获取邻近上下文信息构建全局上下文表征。FRM 采用深度卷积实施空间下采样操作，继而通过双线性插值上采样重构特征图。该过程通过并行提取高频细节特征与低频结构特征，经通道拼接后形成多尺度融合表征。此融合策略不仅实现了局部-全局特征的互补优化，同时通过非线性变换进一步增强了模块的特征表达能力，最终输出具有空间增强与语义强化的精炼特征图。C2f_CFE 整体结构如图 2 所示。



CE, 卷积嵌入模块; CoT, 全局上下文模块; FRM, 特征精炼模块; DWConv, 深度卷积; Fusion, 特征融合模块。下同。


CE, Convolutional embedding; CoT, Contextual transformer; FRM, Feature refinement module. The same as below.

图 2 C2f_CFE 结构

Fig. 2 C2f_CFE structure

1.1.3 轻量级共享卷积检测头 (DLSCD)

在杂草检测中，模型的效率和复杂性直接影响其在实际农业环境中的部署和应用。YOLO 系列采用不同特征级别的独立检测头，每个检测头由 3 个分支组成，以管理不同规模的同一目标。然而，这些分支独立运行，从而导致参数利用效率低下，并增加模型过拟合的风险。在 YOLOv8 基准模型中，检测头参数占总网络参数的 25.0%，而计算成本为 36.4%。为了进一步降低模型复杂性并增强其对资源有限设备的适用性，本研究提出了一种新的轻量级检测头结构 DLSCD。针对参数利用率低的问题，本研究采用了共享卷积结构的理念，并将其引入检测头，使不同的分支能够共享卷积层。同时，使用 Deep 组归一化 (Deep Group normalization, DEG) 模块进一步对局部空间上下文进行融合，增强特征表示，提高捕获全局特征和处理复杂背景时的稳健性和适应性。DEG 模块包括一个普通卷积和一个深度卷积，为杂草检测提供了更高效的解决方案，提升了实际农业应用中的部署效率，并增强了跨场景的扩展能力。DLSCD 的结构如图 3 所示。



DEG, 深度组归一化模块; Con_Cls, 分类分支; Con_Reg, 回归分支

DEG, Deep group normalization

图3 DLSCD 结构

Fig. 3 DLSCD structure

1.1.4 MSDA 注意力模块

研究发现, 杂草检测环境普遍含有遮挡情况, 极大限制了检测精度。为此, 本文在主干网络中加入一种多尺度空洞注意力 MSDA^[15], 旨在结合浅层特征的局部细节和稀疏特性, 通过多尺度建模提升模型的表征能力。本文将基线模型中的 3 种膨胀率扩展为 4 种膨胀率, 以便更有效地扩大感受野, 加强模型对遮挡物体的检测性能。

MSDA 模块由以下几部分构成: 1) 输入特征划分, 即将输入特征划分为多个注意力头 (heads); 2) 滑动窗口空洞注意力 (sliding window dilated attention, SWDA), 在每个注意力头中, 通过调整膨胀率 (dilation rate), 等间隔选取窗口内关键位置的特征块 (patch), 在稀疏窗口内执行注意力操作; 3) 多尺度融合, 对不同的注意力头采用不同的膨胀率 (如 1, 2, 3), 在不同尺度上捕获特征; 4) 结果聚合, 将每个注意力头的结果拼接, 经过线性层整合输出, 形成最终的多尺度语义表示。

在本文中, MSDA 模块采用多头的设计, 将特征图的通道由 3 个头部分为 4 个头, 并在不同的头部使用不同的膨胀率执行 SWDA。这样可以在被关注的感受野的各个尺度上更好地聚合语义信息, 并有效地减少自注意力机制的冗余, 无需复杂的操作和额外的计算成本。在 SWDA 中, 通过设定膨胀率来决定窗口中 key (键) 和 value (值) 的采样间隔, 避免全局计算, 从而显著降低计算量。例如, 稀疏率为 2 时, 每隔 1 个像素选择 1 次。本文中共设置 4 个膨胀率, 分别为 1、2、3、4, 对应捕获 3×3 、 5×5 、 7×7 和 9×9 的感受野。其中, 小膨胀率关注细粒度的局部特征, 大膨胀率则能捕获更大范围的上下文信息。

在 SWDA 中输出 Y 可以表示为:

$$Y = \text{SWDA}(Q, K, V, r)。 \quad (12)$$

式 (12) 中: r 为膨胀率, Q 、 K 、 V 分别为普通注意力中的查询矩阵、键矩阵和值矩阵。

对于位置 (i, j) , SWDA 操作输出 Y 的相应分量 y_{ij} , 定义如下:

$$y_{ij} = \text{Attention}(q_{ij}, K_r, V_r) = \text{Soft max} \left(\frac{q_{ij} K_r^T}{\sqrt{d_k}} \right) V_r。 \quad (13)$$

式 (13) 中: $1 \leq i \leq W, 1 \leq j \leq H$, H 和 W 分别为特征图的高度和宽度; K_r 和 V_r 表示根据膨胀率从

特征图 K 和 V 中选择的键和值。当查询位置为 (i, j) 时, 键和值位于 (i', j') 处:

$$\{(i', j') | i' = i + p \times r, j' = j + q \times r\}, -\frac{w}{2} \leq p, q \leq \frac{w}{2}。 \quad (14)$$

式 (14) 中: 滑动窗口大小为 $w \times w$, p, q 为 $\left(-\frac{w}{2}, \frac{w}{2}\right)$ 范围内的整数。

对于特征映射边缘的查询, 使用卷积操作中常用的零填充策略来保持特征映射的大小。在 MSDA 的实现框架下, 原始特征张量 X 经线性变换层生成对应的查询、键、值向量。然后, 将特征图的通道划分为 4 个不同的头部, 并对膨胀率不同的头部进行多尺度 SWDA。具体来说, 本文的 MSDA 采用分治策略对不同感受野的特征单元进行处理, 表述式如下:


$$h_i = \text{SWDA}(Q_i, K_i, V_i, r_i), 1 \leq i \leq n; \quad (15)$$

式 (15) 中: r_i 为第 i 个头部的膨胀率; Q_i 、 K_i 和 V_i 表示输入第 i 个头部的特征图。

输出的 h_i 被连接到一起, 再经过一个线性层进行特征聚合。

$$Y = \text{Linear}[\text{Concat}(h_1, \dots, h_n)]。 \quad (16)$$

如图 4 是 MSDA 流程图。



Linear, 全连接层。

图 4 MSDA 流程

Fig. 4 MSDA process

1.1.5 CCFM 结构

YOLOv8 采用改进的双向特征金字塔网络（path aggregation feature pyramid network, PAN-FPN）实现多尺度特征融合，通过整合浅层空间信息与深层语义特征提升检测性能。然而，其多层级联结构存在参数量冗余问题，导致计算效率下降。为优化特征融合效率，本研究引入 CCFM^[16]替代原颈部网络。

CCFM 在 Swin Transformer^[17]的多尺度特征融合策略基础上，通过尺度内特征交互与跨尺度特征融合策略，在减少参数量的同时提升特征表征能力。CCFM 选取主干网络中第 5 层、第 7 层和第 11 层 3 个尺度的输出，分别作为 S3、S4 和 S5 层的输入，输出通道数分别为 256、512、1 024。通过使用若干 1×1 卷积将所有特征通道数映射为 256，然后再进行特征融合，减少下采样时的参数冗余。

如图 5 是本文中 CCFM 结构图。




图 5 CCFM 结构

Fig. 5 CCFM structure

特征融合采用级联式通道拼接（Concat）模块，按照通道维度对不同层的特征进行拼接。具体流程如下：首先，将高层特征 S5 层的输出经过卷积和上采样后，与中层特征 S4 层的输出经过卷积映射后的结果拼接生成 O_1 ； O_1 经过 C2f_CFE、卷积、上采样模块后，与浅层特征 S3 经过卷积映射后的结果融合，生成输出 O_2 。 O_2 经过一个 C2f_CFE 和卷积后，与经过 C2f_CFE 和卷积的 O_1 融合生成输出 O_3 ； O_3 经过 C2f_CFE、卷积后，与经过映射后的 S5 特征生成输出 O_4 。最后，输出结果包括 O_2 、 O_3 和 O_4 。该过程通过参数共享的轻量化卷积操作实现特征交互，显著降低冗余计算。

1.2 数据集

如今多数可用的数据集都存在数据缺乏可变性（个体或植物物种数量少）的问题，大部分数据集都只有小部分杂草种类，并且没有杂草的生长动态信息，绝大多数都是杂草成熟后的样本。针对上述问题，Genze 等^[18]创建了一个具有高时间和空间分辨率的包含不同植物物种的高质量数据集（Moving Fields Weed Dataset, MFWD），其中包括 28 种常见杂草类型、6 种高粱和 2 种玉米，每个物种单独标记，记录其从发芽到成熟

各个阶段的图像，并使用 EPPO 代码作为类标签。由于种子分类并不完全纯净，还包括部分不属于上述 36 种植物的杂草，将其统一标注为 weed，故整个数据库共包含 37 种植物。研究显示，MFWD 数据集中各种植物的种类数量与分布特征相对均衡，具有较高的时空多样性和尺度变化，适用于评估模型在多场景下的稳健性。

本文从 MFWD 的每种植物中选择 3 个周期（将包括植物发芽、成长、成熟等多个阶段于一体的视为一个周期），在每个周期的每个阶段随机选取数据，保证植物每个阶段的图片数量大致相等，共选择 3 449 张图片用于研究，将其按照 6:2:2 的比例随机划分为训练集、验证集和测试集，分别包含 2 069、691、689 张图片。

1.3 评价指标

本研究采用平均精度均值[mean average precision, mAP, 交并比 (IoU) 阈值为 0.5]、参数量 (Param)、模型计算量[以浮点运算次数 (FLOPs) 表示]，以及推理帧率[以每秒帧数 (frames per second, FPS) 表示]这 4 个评价指标来综合评估模型的性能表现。

1.4 实验环境


本实验所用设备搭载 Ubuntu 22.04 Linux 系统，代码编写环境为 PyCharm 编辑器；硬件配置如下：Intel® Xeon® Silver 4210 CPU @ 2.20 GHz、NVIDIA TITAN RTX (24 GB 显存)，内存 32 GB。实验基于 Python 3.9 编程语言、PyTorch 2.3.1 深度学习框架，搭配 CUDA 12.1 并行加速工具，采用随机梯度下降 (stochastic gradient descent, SGD) 优化器训练模型，总训练轮次 (epoch) 设置为 300，批次大小 (batch size) 为 16，数据加载线程数 (workers) 设置为 8。实验未加载预训练权重，其余超参数均采用框架默认配置。

推理环境：为准确评估模型部署性能，所有 FPS 指标均在纯 GPU 推理环境下测试。输入图像的分辨率统一转换为 640 pixel×640 pixel。

2 结果与分析

2.1 不同注意力机制对比

为了验证多尺度空洞注意力机制对遮挡物体的检测情况，本研究选取 YOLOv8n 作为基准模型，同时引入多种经典注意力机制作为对比，包括卷积块注意力模块 (convolutional block attention module, CBAM)、坐标注意力 (coordinate attention, CA)、通道注意力 (squeeze-and-excitation, SE)、全局注意力机制 (global attention mechanism, GAM)、增强多尺度通道注意力 (enhanced multi-scale channel attention, EMCA)、高效通道注意力 (efficient channel attention, ECA)、MSDA。与基线模型相比，引入一般的通道注意力机制，如 CA、SE 后，模型的 mAP 分别提升了 0.4、0.5 百分点（图 6）；引入空间-通道注意力机制，如 CBAM、GAM 后，模型的 mAP 分别提升了 0.7、0.5 百分点；引入跨通道注意力机制，如 ECA、EMCA 后，模型的 mAP 分别提升了 0.8、0.4 百分点；而引入 MSDA 后，mAP 增长 1.1 百分点，说明 MSDA 能更好地融合多尺度特征，提高检测精度。



SE, 通道注意力; ECA, 高效通道注意力; CBAM, 卷积块注意力模块; CA, 坐标注意力; GAM, 全局注意力机制; EMCA, 增强多尺度通道注意力; MSDA, 多尺度空洞注意力。上述注意力机制均默认添加至基线模型 (YOLOv8n) 的主干网络中。CK 表示基线模型。MSDA 默认添加至模型的主干网络中, 膨胀率设定为 4。MSDA-h 和 MSDA-n 分别表示将 MSDA 添加至模型的颈部和头部网络中, 膨胀率均设定为 4; MSDA-3 表示将 MSDA 添加至模型的主干网络中, 但膨胀率为 3。

SE, Squeeze-and-excitation; ECA, Efficient channel attention; CBAM, Convolutional block attention module; CA, Coordinate attention; GAM, Global attention mechanism; EMCA, Enhanced multi-scale channel attention; MSDA, Multi-scale dilated attention. All the above attention mechanisms are embedded into the backbone network of the baseline model (YOLOv8n) by default. CK refers to the baseline model. MSDA is added to the backbone network by default with a dilation rate of 4. MSDA-h and MSDA-n denote the configurations where MSDA is embedded into the neck and detection head of the model, respectively, both with a dilation rate of 4. MSDA-3 represents the scheme where MSDA is integrated into the backbone network with a dilation rate set to 3.

图 6 不同注意力机制的平均精度均值 (mAP)

Fig. 6 Mean average precision (mAP) under different attentino mechanisms

为测试 MSDA 在不同位置对不同特征层的检测能力, 将其分别添加在模型的主干网络 (backbone)、颈部网络 (neck) 和头部网络 (head) 中进行测试。结果表明, MSDA 在 backbone 中使用的效果最佳, mAP 较基线模型提升了 1.1 百分点, 而在 neck 和 head 中添加 MSDA 时, mAP 分别提升 0.9、0.6 百分点%。这可能是因为, MSDA 在提取浅层信息时效果最好, 在提取高级的抽象信息时效果不佳。

对比 MSDA 中膨胀率设定对结果的影响发现, 膨胀率设定为 4 时的 mAP 更高, 证明该设置能更好地扩大感受野, 应对叶间遮挡的情况。

2.2 不同模型对比

为了验证改进模型的效果, 将本文提出的模型与现有的 Faster R-CNN、YOLOv6、YOLOv7-tiny^[19]、YOLOv8n、YOLOv9t^[20]、YOLOv10n^[21]、YOLOv11^[22]、RT-DETR-l 模型进行对比, 训练轮次 (epoch) 均为 300。结果 (表 1) 显示, 在 YOLO 系列中尽管 YOLOv8n 的平均精度均值并不是最高的, 但其推理帧率最高, 更符合实际高速响应的需求, 这也验证了本研究选择 YOLOv8n 作为基准模型的合理性。与基准模型 YOLOv8n 相比, CDMC-YOLO 模型的参数量减少了 40.0%, 计算量减少了 23.2%, mAP 提升了 2.1 百分点。与双阶段模型 Faster R-CNN, 以及单阶段模型的 YOLOv6、YOLOv7-tiny、YOLOv9t、YOLOv10n、YOLOv11 模型相比, CDMC-YOLO 模型的参数量、计算量最小, mAP 更高。与 RT-DETR 模型相比, 虽然 CDMC-YOLO 模型 mAP 略低, 但其参数量和计算量要小得多。RT-DETR 模型的 mAP 值虽然最高, 但不满足实际环境中实时性和部署在边缘设备上的需求。本研究提出的 CDMC-YOLO 模型的参数量、计算量小, 精度高, 能更好地运用在实际生产中。

进一步对比本文模型与 YOLOv8n 模型对不同杂草种类的检测精度，发现本文模型对绝大多数杂草种类的 mAP 都较 YOLOv8n 模型有所提升，提升最大的是 GASPA 类（14.2%）、ALOMY 类（5.9%）、GALAP 类（5.5%）。其中，GASPA 类由于夹杂了多种杂草类型，YOLOv8n 的检测精度较低，但在 CDMC-YOLO 模型中检测精度提高，验证了 CDMC-YOLO 对杂草边缘特征的检测能力；GALAP 类由于出现多株植物互相遮挡的情况，YOLOv8n 模型的检测精度也不高，而 CDMC-YOLO 模型的表现较好，说明本文模型能更好地对边缘不清、遮挡情况下的杂草进行检测。

表 1 不同模型的结果对比

Table 1 Comparison of results for different models

模型 Model	Param/MB	mAP/%	FLOPs/10 ⁹	FPS
Faster R-CNN	134.6	84.3	360.4	11
YOLOv6	4.3	89.6	12.0	25
YOLOv7-tiny	6.0	94.1	13.2	17
YOLOv8n	3.0	93.0	8.2	47
YOLOv9t	1.8	92.7	6.7	14
YOLOv10n	2.7	93.8	8.5	33
RT-DETR-l	32.9	95.3	108	52
YOLOv11	2.6	93.4	6.5	32
CDMC-YOLO	1.8	95.1	6.3	56

Param, 参数量; mAP, 平均精度均值[交并比 (IoU) 阈值为 0.5]; FLOPs, 浮点运算次数; FPS, 每秒帧数。下同。

Param, Parameters; mAP, Mean average precision at an IoU (Intersection over Union) threshold of 0.5; FLOPs, Floating point of operations; FPS, Frames per second. The same as below.

2.3 消融实验

为逐步评估各模块对基础模型的性能贡献，本研究将 C2f_CFE、DLSCD、MSDA、CCFM 依次渐进式集成至 YOLOv8n 基准架构中，所有实验均保持前述配置不变。鉴于 CCFM 已实现颈部网络输出特征图的维度对齐，因此本实验方案未另行引入维度统一操作。在单独部署 DLSCD 模块的实验中，需在其处理链路前端增设一层卷积层，以统一输入特征图的维度。

结果（表 2）显示：只添加 CCFM 时，模型的参数量下降 20.0%，计算量下降 14.6%，mAP 增加 0.4 百分点；只添加 DLSCD 时，模型的参数量下降 23.3%，计算量下降 18.3%，mAP 增加 0.3 百分点；同时加入 CCFM 和 DLSCD 时，模型的参数量下降 46.7%，计算量下降 30.5%，mAP 增加 0.6 百分点；单独加入 MSDA 后，模型的 mAP 增加 1.1% 百分点，参数量增加 6.7%，计算量增加 8.5%；单独加入 C2f_CFE 模块后，模型的 mAP 增加 1.6 百分点，参数量增加了 6.7%，计算量增加 3.6%；同时引入上述 4 项改进时，模型的参数量下降 40.0%，计算量下降 23.2%，mAP 增加 2.1 百分点，证明了本文方法的整体有效性与泛化性。

表 2 消融实验结果

Table 2 Ablation experiment results

CCFM	DLSCD	MSDA	C2f_CFE	Param/MB	mAP/%	FLOPs/10 ⁹	FPS
—	—	—	—	3.0	93.0	8.2	47
√	—	—	—	2.4	93.4(+0.4)	7.0	49
—	√	—	—	2.3	93.3(+0.3)	6.7	55
—	—	√	—	3.2	94.1(+1.1)	8.9	33

—	—	—	√	3.2	94.6(+1.6)	8.5	48
√	√	—	—	1.6	93.6(+0.6)	5.7	53
√	√	√	—	1.7	94.3(+1.3)	5.8	51
√	√	√	√	1.8	95.1(+2.1)	6.3	56

“√”表示向基线模型中引入该结构/模块；“—”表示不引入该结构/模块。

"√" indicates that the corresponding structure/module is incorporated into the baseline model; "—" means the structure/module is not adopted.

2.4 检测效果分析

为验证本文模型对遮挡环境和小目标的检测能力，将 CDMC-YOLO 与基准模型 YOLOv8 进行对比，选取 3 张不同种类的杂草图像进行检测。结果（图 7）显示，在处理诸如杂草幼苗等小型目标和多株植物间的遮挡问题时，CDMC-YOLO 模型展现出相较于 YOLOv8 模型更高的置信度。针对特征不甚显著的杂草样本，YOLOv8 模型出现了一定程度的检测遗漏现象，而 CDMC-YOLO 模型则能够实现全面检出。然而，对于那些刚刚萌芽、其主要特征尚未充分显现的极小杂草个体，无论是 YOLOv8 还是 CDMC-YOLO 模型，目前均未能达到完全的检测效能。




图 7 杂草检测结果对比

Fig. 7 Comparison of weed detection results

3 结论

针对现有的杂草检测算法参数过多，占用的内存量较大，对遮挡、多尺度特征、背景混乱情况下检测能力不足的问题，本文在 YOLOv8n 模型的基础上进行改进：1）设计一种新型特征增强模块 C2f_CFE，提高模型对边缘不清、多尺度特征情况的检测能力；2）设计一种轻量级共享卷积检测头，减少参数量与计算开销；3）在主干网络中加入 MSDA，扩大模型感受野，提高对遮挡情况下的检测能力；4）引入 CCFM 对不同尺度的特征进行高效融合，减少冗余计算量，增强模型对多尺度目标的检测能力。结果表明，改进后的模型在检测精度、参数量、计算量与推理帧率上均优于 YOLOv8n、Faster R-CNN、YOLOv11 等模型，为农业

边缘设备的实时杂草检测提供了高效解决方案。

虽然该模型对多种杂草和不同时期的杂草检测都具有较高的准确度,但在实际环境下,对多种杂草之间相互遮挡、复杂天气环境影响以及刚发芽还未表露出特征的杂草幼苗检测上还有改进空间。未来,可通过融合高光谱成像来增强幼苗特征表达或构建多样数据集来解决上述问题。

参考文献 (References) :

- [1] LI J J, CHEN D, YIN X Y, et al. Performance evaluation of semi-supervised learning frameworks for multi-class weed detection[J]. *Frontiers in Plant Science*, 2024, 15: 1396568.
- [2] KHOTIMAH W N, BENNAMOUN M, BOUSSAID F, et al. A high-performance spectral-spatial residual network for hyperspectral image classification with small training data[J]. *Remote Sensing*, 2020, 12(19): 3137.
- [3] SULAIMAN N, CHE'YA N N, MOHD ROSLIM M H, et al. The application of hyperspectral remote sensing imagery (HRSI) for weed detection analysis in rice fields: a review[J]. *Applied Sciences*, 2022, 12(5): 2570.
- [4] MURAD N Y, MAHMOOD T, FORKAN A R M, et al. Weed detection using deep learning: a systematic literature review[J]. *Sensors*, 2023, 23(7): 3670.
- [5] COLEMAN G R Y, BENDER A, HU K, et al. Weed detection to weed recognition: reviewing 50 years of research to identify constraints and opportunities for large-scale cropping systems[J]. *Weed Technology*, 2022, 36(6): 741-757.
- [6] FAN X P, SUN T, CHAI X J, et al. YOLO-WDNet: a lightweight and accurate model for weeds detection in cotton field[J]. *Computers and Electronics in Agriculture*, 2024, 225: 109317.
- [7] DING Y M, JIANG C, SONG L, et al. RVDR-YOLOv8: a weed target detection model based on improved YOLOv8[J]. *Electronics*, 2024, 13(11): 2182.
- [8] 文韬, 王天一, 黄诗锐, 等. 基于改进 YOLOv8 的农作物与藜草检测算法: MES-YOLO[J/OL]. 计算机工程与科学, 2024-10-12. <https://kns.cnki.net/KCMS/detail/detail.aspx?filename=JSJK20241010003&dbname=CJFD&dbcode=CJFQ>.
- WEN T, WANG T Y, HUANG S R, et al. Improved crop and pigweed detection algorithm based on YOLOv8: MES-YOLO[J/OL]. *Computer Engineering & Science*, 2024-10-12. <https://kns.cnki.net/KCMS/detail/detail.aspx?filename=JSJK20241010003&dbname=CJFD&dbcode=CJFQ>. (in Chinese with English abstract)
- [9] LI W W, ZHANG Y. DC-YOLO: an improved field plant detection algorithm based on YOLOv7-tiny[J]. *Scientific Reports*, 2024, 14: 26430.
- [10] KAVITHA S, GANGAMBIKA G, PADMINI K, et al. Automatic weed detection using CCOA based YOLO network in soybean field[C]//2024 Second International Conference on Data Science and Information System (ICDSIS). May 17-18, 2024, Hassan, India. IEEE, 2024: 1-8.
- [11] 冯泰桃, 张雪松, 宋存利, 等. 改进 YOLOv7 的小目标检测方法[J]. 计算机工程与应用, 2025, 61(10): 203-213.
- FENG T L, ZHANG X S, SONG C L, et al. Improved small object detection method of YOLOv7[J]. *Computer Engineering and Applications*, 2025, 61(10): 203-213. (in Chinese with English abstract)
- [12] ZHENG L, ZHU C G, LIU L, et al. Star-YOLO: a lightweight and efficient model for weed detection in cotton fields using advanced YOLOv8 improvements[J]. *Computers and Electronics in Agriculture*, 2025, 235: 110306.
- [13] VARGHESE R, M S. YOLOv8: a novel object detection algorithm with enhanced performance and robustness[C]//2024 International Conference on Advances in Data Engineering and Intelligent Computing Systems (ADICS). April 18-19, 2024, Chennai, India. IEEE, 2024: 1-6.
- [14] ALI M, JAVAID M, NOMAN M, et al. FANet: feature amplification network for semantic segmentation in cluttered background[C]//2024 IEEE International Conference on Image Processing (ICIP), October 27-30, 2024, Abu Dhabi, United Arab Emirates. New York: IEEE, 2024: 2592-2598.
- [15] JIAO J Y, TANG Y M, LIN K Y, et al. DilateFormer: multi-scale dilated transformer for visual recognition[J]. *IEEE Transactions on Multimedia*, 2023, 25: 8906-8919.
- [16] ZHAO Y A, LV W Y, XU S L, et al. DETRs beat YOLOs on real-time object detection[C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). June 16-22, 2024, Seattle, WA, USA. IEEE, 2024: 16965-16974.
- [17] LIU Z, LIN Y T, CAO Y, et al. Swin transformer: hierarchical vision transformer using shifted windows[C]//2021 IEEE/CVF International Conference on Computer Vision (ICCV). October 10-17, 2021, Montreal, QC, Canada. IEEE, 2021: 9992-10002.
- [18] GENZE N, VAHL W K, GROTH J, et al. Manually annotated and curated dataset of diverse weed species in maize and sorghum for computer vision[J]. *Scientific Data*, 2024, 11: 109.

- [19] WANG C Y, BOCHKOVSKIY A, LIAO H M. YOLOv7: trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). June 17-24, 2023, Vancouver, BC, Canada. IEEE, 2023: 7464-7475.
- [20] WANG C Y, YEH I H, MARK LIAO H Y. YOLOv9: learning what you want to learn using programmable gradient information[M]//*Computer Vision – ECCV 2024*. Cham: Springer Nature Switzerland, 2024: 1-21.
- [21] WANG A, CHEN H, LIU L H, et al. Yolov10: real-time end-to-end object detection[PP/OL]. V2. arXiv (2024-10-30) [2025-07-19].
<https://arxiv.org/abs/2405.14458>.
- [22] KHANAM R, HUSSAIN M. YOLOv11: an overview of the key architectural enhancements[PP/OL]. arXiv (2024-10-23) [2025-07-19].
<https://arxiv.org/abs/2410.17725>

(责任编辑 高 峻)